ĐẠI HỌC QUỐC GIA, THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

KHAI PHÁ DỮ LIỆU (CO3029)

Assignment

"PHÂN TÍCH DỮ LIỆU THỜI TIẾT DỰ BÁO MƯA VÀ THỜI TIẾT CỰC ĐOAN"

GVHD: Đỗ Thanh Thái

Students: Kiều Tấn Anh Minh - 2312065 *(Group L03 - Team 03)*
Bùi Thị Ngọc Huyền - 2311271 *(Group L03 - Team 03)*
Hồ Bắc Nam - 2312157 *(Group L03 - Team 03)*

https://github.com/itzKieuMinh05/CO3029-Weather_forecasting

Thành phố Hồ Chí Minh, Tháng 4/2026

Contents

1 Tổng quan bài toán **4**

2 Mô tả và tiền xử lý dữ liệu **4**
2.1 Mô tả tập dữ liệu 4
2.2 Tiền xử lý dữ liệu 5
2.2.1 Tổng hợp dữ liệu 5
2.2.2 Loại bỏ dữ liệu trùng lặp 5
2.2.3 Xử lý và trích xuất đặc trưng thời gian 6
2.2.4 Chuẩn hóa và rút gọn dữ liệu 6
2.2.5 Xử lý giá trị thiếu 6
2.2.6 Xây dựng đặc trưng mới 6
2.2.7 Rời rạc hóa dữ liệu 7

3 Khai phá luật kết hợp qua Apriori và FPGrowth **7**
3.1 Mục tiêu 7
3.2 Cơ sở lý thuyết 7
3.3 Quá trình thực thi 8
3.3.1 Chuẩn bị dữ liệu 8
3.3.2 Biểu diễn dữ liệu dưới dạng transaction 9
3.3.3 Huấn luyện mô hình FPGrowth 10
3.3.4 Trích xuất và lọc luật kết hợp 11
3.3.5 Trực quan hóa và phân tích 11

4 Xây dựng mô hình gom cụm (Clustering Algorithsm) **13**
4.1 Mục tiêu 13
4.2 Cơ sở lý thuyết 13
4.2.1 Nguyên lý hoạt động 13
4.2.2 Quy trình thực thi 14
4.3 Các kỹ thuật bổ trợ trong bài toán 14
4.3.1 Chuẩn hoá dữ liệu 14
4.3.2 Phương pháp xác định K tối ưu 14
4.3.3 Giảm chiều dữ liệu với PCA 15
4.4 Phân tích kết quả và nhận xét 15
4.4.1 Xác định số cụm tối ưu 15
4.4.2 Đặc điểm của các cụm 15
4.4.3 Nhận xét chi tiết 16
4.4.4 Phân tích không gian PCA 17
4.4.5 Kết luận 18

5 Phân loại thời tiết cực đoan bằng học máy (Classification) **18**
5.1 Mục tiêu của bài toán phân lớp 18
5.2 Giới thiệu và khắc phục mất cân bằng dữ liệu 19
5.3 Đánh giá tổng quan qua các chỉ số (Metrics) 19
5.4 Phân tích chi tiết: Dự đoán mưa (Rain) 20
5.5 Phân tích chi tiết: Cảnh báo thời tiết cực đoan (Extreme) 21

6 Giao diện trực quan hệ thống **21**

7 Kết luận và ra quyết định **25**

8 Link github và slide của dự án **25**

Member list & Workload

No.	Fullname	Student ID	Problems	% done
1	Kiều Tấn Anh Minh	2312065	- Thực hiện khai phá luật kết hợp - Thực hiện giao diện hệ thống - Viết report	100%
2	Bùi Thị Ngọc Huyền	2311271	- Thực hiện mô hình gom cụm - Làm slide - Viết report	100%
3	Hồ Bắc Nam	2312157	- Thực hiện classification - Làm slide - Viết report	100%

Table 1: Member list & workload

1 Tổng quan bài toán

Trong bối cảnh biến đổi khí hậu ngày càng phức tạp, việc phân tích và dự báo các hiện tượng thời tiết đóng vai trò quan trọng trong nhiều lĩnh vực như nông nghiệp, giao thông vận tải, quy hoạch đô thị và quản lý rủi ro thiên tai. Đặc biệt, các hiện tượng thời tiết cực đoan như nắng nóng kéo dài, mưa lớn hoặc bão có thể gây ra những tác động nghiêm trọng đến đời sống kinh tế – xã hội.

Bài toán đặt ra trong đề tài này là khai thác và phân tích dữ liệu thời tiết thực tế tại Việt Nam nhằm phục vụ hai mục tiêu chính: (1) phát hiện các mối quan hệ tiềm ẩn giữa các yếu tố khí tượng, và (2) xây dựng mô hình dự đoán khả năng xảy ra mưa cũng như các hiện tượng thời tiết cực đoan.

Dữ liệu được sử dụng là tập dữ liệu thời tiết thời gian thực thu thập từ nhiều thành phố trên cả nước thông qua API của OpenWeatherMap. Tập dữ liệu này bao gồm các thông tin khí tượng quan trọng như nhiệt độ, độ ẩm, áp suất, tốc độ gió, lượng mưa và các đặc trưng liên quan đến thời gian. Với đặc thù có độ phân giải thời gian cao và phân bố rộng theo không gian địa lý, dữ liệu phù hợp cho các bài toán khai phá dữ liệu và học máy.

Để giải quyết bài toán, đề tài triển khai một quy trình xử lý và phân tích dữ liệu toàn diện, bao gồm các bước chính như sau:

- **Tiền xử lý dữ liệu:** Làm sạch, xử lý giá trị thiếu, chuẩn hóa và xây dựng thêm các đặc trưng nhằm nâng cao chất lượng dữ liệu đầu vào.
- **Khai phá luật kết hợp:** Áp dụng thuật toán FPGrowth và Apriori để tìm ra các mối quan hệ giữa các yếu tố thời tiết và các hiện tượng như mưa hoặc nắng nóng.
- **Phân cụm dữ liệu:** Sử dụng thuật toán K-Means để nhóm các thành phố có đặc điểm khí hậu tương đồng, từ đó phát hiện các cấu trúc tiềm ẩn trong dữ liệu.
- **Phân loại bằng học máy:** Xây dựng và đánh giá các mô hình như Random Forest và XGBoost nhằm dự đoán khả năng xảy ra mưa và các hiện tượng thời tiết cực đoan.
- **Trực quan hóa và xây dựng giao diện:** Phát triển hệ thống giao diện bằng Streamlit giúp người dùng dễ dàng quan sát dữ liệu, kết quả phân tích và thực hiện dự đoán.

Thông qua các bước trên, đề tài không chỉ dừng lại ở việc xây dựng mô hình dự đoán mà còn hướng đến việc cung cấp các insight có giá trị, hỗ trợ quá trình ra quyết định trong thực tế. Kết quả của nghiên cứu kỳ vọng sẽ góp phần nâng cao khả năng dự báo và cảnh báo sớm các hiện tượng thời tiết, từ đó giảm thiểu rủi ro và thiệt hại trong nhiều lĩnh vực ứng dụng.

2 Mô tả và tiền xử lý dữ liệu

2.1 Mô tả tập dữ liệu

Dataset được sử dụng trong đề tài là tập dữ liệu thời tiết thời gian thực tại Việt Nam. Dữ liệu được thu thập từ 78 thành phố thuộc 63 tỉnh/thành, phản ánh ranh giới hành chính trước thời điểm sáp nhập tỉnh vào ngày 12/06/2025. Toàn bộ dữ liệu được tổng hợp dưới dạng một tệp CSV thống nhất.

Dữ liệu được thu thập thông qua API của *OpenWeatherMap* bằng các script tự động viết bằng Python. Mỗi thành phố được truy vấn với tần suất từ 2 đến 4 phút, đảm bảo độ phân giải thời gian cao và phù hợp cho các bài toán phân tích chuỗi thời gian.

Mục tiêu của dataset là cung cấp nguồn dữ liệu thời tiết chi tiết ở cấp độ thành phố tại Việt Nam, phục vụ cho các bài toán như phân tích xu hướng thời tiết, trực quan hóa dữ liệu địa lý, và xây dựng các mô hình học máy dự báo (ví dụ: LSTM, Prophet). Nguồn dữ liệu được lấy từ https://www.kaggle.com/datasets/lduyhi/vietnam-real-time-weather-data/data

Các cột có trong dữ liệu được mô tả như sau:

Thuộc tính	**Kiểu dữ liệu**	**Mô tả**
time	datetime	Thời điểm ghi nhận dữ liệu
province	string	Tên tỉnh/thành phố cấp tỉnh
city	string	Tên thành phố hoặc khu vực quan trắc
temperature	float	Nhiệt độ hiện tại (°C)
temp_min	float	Nhiệt độ thấp nhất (°C)
temp_max	float	Nhiệt độ cao nhất (°C)
feels_like	float	Nhiệt độ cảm nhận (°C)
humidity	integer	Độ ẩm không khí (%)
pressure	integer	Áp suất khí quyển (hPa)
visibility	integer	Tầm nhìn (mét)
precipitation	float	Lượng mưa (mm)
cloudcover	integer	Mức độ che phủ mây (%)
wind_speed	float	Tốc độ gió (m/s)
wind_gust	float	Tốc độ gió giật (m/s)
wind_direction	integer	Hướng gió (độ)
is_day	boolean	Xác định ban ngày (1) hoặc ban đêm (0)
weather_code	integer	Mã thời tiết
weather_main	string	Nhóm thời tiết chính
weather_description	string	Mô tả chi tiết thời tiết
weather_icon	string	Mã biểu tượng thời tiết

Table 2: Mô tả các thuộc tính trong dataset thời tiết

2.2 Tiền xử lý dữ liệu

Quá trình tiền xử lý dữ liệu được thực hiện nhằm làm sạch, chuẩn hóa và xây dựng thêm các đặc trưng phục vụ cho phân tích và mô hình hóa. Các bước cụ thể như sau:

2.2.1 Tổng hợp dữ liệu

Dữ liệu được thu thập từ nhiều tệp CSV khác nhau và được hợp nhất thành một tập dữ liệu duy nhất. Cụ thể, các tệp có định dạng *weather-vn-*.csv* được đọc và nối lại bằng phương pháp *concatenation*.

2.2.2 Loại bỏ dữ liệu trùng lặp

Các bản ghi trùng lặp được loại bỏ nhằm đảm bảo tính chính xác và tránh ảnh hưởng đến kết quả phân tích:

- Sử dụng hàm *drop_duplicates()* để loại bỏ các dòng bị lặp.

2.2.3 Xử lý và trích xuất đặc trưng thời gian

Thuộc tính *time* được chuyển đổi sang định dạng *datetime*. Từ đó, các đặc trưng thời gian quan trọng được trích xuất bao gồm:

- Giờ trong ngày (*hour*)
- Ngày trong tháng (*day*)
- Tháng (*month*)
- Thứ trong tuần (*weekday*)

2.2.4 Chuẩn hóa và rút gọn dữ liệu

Thuộc tính *province* được loại bỏ nhằm tránh dư thừa thông tin do đã có thuộc tính *city*. Đồng thời, các thành phố được ánh xạ vào ba vùng địa lý chính:

- Miền Bắc (*north*)
- Miền Trung (*central*)
- Miền Nam (*south*)

Các giá trị không thuộc ba nhóm trên được gán là *unknown*.

2.2.5 Xử lý giá trị thiếu

Các giá trị thiếu được xử lý như sau:

- Với các thuộc tính số: thay thế bằng giá trị trung vị (median).
- Với các thuộc tính phân loại: thay thế bằng giá trị xuất hiện nhiều nhất (mode).

2.2.6 Xây dựng đặc trưng mới

Một số đặc trưng mới được tạo ra nhằm tăng khả năng biểu diễn dữ liệu:

- **Biên độ nhiệt độ**:
  - Tính toán chênh lệch giữa nhiệt độ cao nhất và thấp nhất trong ngày theo từng thành phố.
- **Biểu diễn hướng gió**:
  - Chuyển đổi hướng gió từ dạng góc sang dạng vector thông qua hàm sin và cos.
- **Biến mưa (rain)**:
  - Chuyển đổi lượng mưa thành biến nhị phân (có mưa hoặc không).
- **Thời tiết cực đoan (extreme)**:
  - Phân loại các điều kiện thời tiết đặc biệt như nắng nóng, mưa lớn hoặc bão dựa trên các ngưỡng xác định trước.

2.2.7 Rời rạc hóa dữ liệu

Các thuộc tính liên tục được chuyển thành các mức phân loại để phục vụ cho các thuật toán khai phá luật kết hợp:

- Nhiệt độ: thấp, trung bình, cao
- Độ ẩm: thấp, trung bình, cao
- Áp suất: thấp, bình thường, cao
- Tốc độ gió: thấp, trung bình, cao

3 Khai phá luật kết hợp qua Apriori và FPGrowth

3.1 Mục tiêu

Ở chương này, mục tiêu chính là khai phá các mối quan hệ tiềm ẩn giữa các yếu tố thời tiết và các hiện tượng như mưa hoặc thời tiết cực đoan. Dữ liệu thời tiết sau khi tiền xử lý sẽ được chuyển đổi sang dạng giao dịch (transaction) để áp dụng các thuật toán khai phá luật kết hợp. Cụ thể, các mục tiêu bao gồm:

- Biểu diễn dữ liệu thời tiết dưới dạng các itemset
- Áp dụng thuật toán FPGrowth để tìm các tập phổ biến (frequent itemsets)
- Sinh các luật kết hợp liên quan đến các sự kiện như *rain_yes*, *heatwave*, *heavy_rain*, và *storm*
- Phân tích và so sánh các luật theo từng vùng: Bắc, Trung, Nam

3.2 Cơ sở lý thuyết

Ở thuật toán Apriori, luật kết hợp có dạng:

$$A \rightarrow B$$

trong đó A là tập điều kiện (antecedent) và B là kết quả (consequent).

Các độ đo quan trọng bao gồm:

Support đo tần suất xuất hiện của tập mục:

$$Support(A \rightarrow B) = Support(A \cup B)$$

Confidence đo xác suất xảy ra của B khi A đã xảy ra:

$$Confidence(A \rightarrow B) = \frac{Support(A \cup B)}{Support(A)}$$

Lift đánh giá mức độ liên hệ giữa A và B:

$$Lift(A \rightarrow B) = \frac{Confidence(A \rightarrow B)}{Support(B)}$$

Đối với bài toán này, thuật toán **FPGrowth** được sử dụng thay cho Apriori truyền thống do khả năng xử lý hiệu quả trên dữ liệu lớn và không cần sinh tập ứng viên nhiều lần. FPGrowth (Frequent Pattern Growth) là một thuật toán khai phá tập mục phổ biến (frequent itemsets) dựa trên cấu trúc dữ liệu cây gọi là *FP-Tree*. Thuật toán này giúp nén dữ liệu giao dịch và khai thác trực tiếp các mẫu phổ biến mà không cần sinh ra các tập ứng viên như trong Apriori.

Một tập mục X được xem là phổ biến nếu thỏa mãn điều kiện:

$$Support(X) \geq min_support$$

Trong đó:

$$Support(X) = \frac{\text{số giao dịch chứa } X}{\text{tổng số giao dịch}}$$

Ý tưởng chính của FPGrowth gồm hai bước:

- **Xây dựng FP-Tree:** Duyệt qua tập dữ liệu để xác định các item phổ biến dựa trên ngưỡng *min_support*. Sau đó, các giao dịch được sắp xếp theo thứ tự giảm dần của tần suất và chèn vào cây FP-Tree, giúp biểu diễn dữ liệu một cách nén và hiệu quả.
- **Khai thác FP-Tree:** Từ cây FP-Tree, thuật toán tiến hành xây dựng các cây điều kiện (*conditional FP-Tree*) và sử dụng phương pháp đệ quy để trích xuất các tập mục phổ biến.

Cấu trúc FP-Tree bao gồm các nút chứa tên item, số lần xuất hiện (count), con trỏ đến nút cha và các liên kết giữa các nút cùng loại (node-link). Ngoài ra, một bảng header table được sử dụng để hỗ trợ truy xuất nhanh các item trong cây.

So với Apriori, FPGrowth có các ưu điểm nổi bật như không cần sinh tập ứng viên, giảm số lần quét dữ liệu và đạt hiệu quả cao trên các tập dữ liệu lớn. Nhờ đó, thuật toán phù hợp với bài toán khai phá luật kết hợp trên dữ liệu thời tiết có kích thước lớn và nhiều thuộc tính như trong đề tài này.

3.3 Quá trình thực thi

3.3.1 Chuẩn bị dữ liệu

Dữ liệu thời tiết đầu vào đã được tiền xử lý và rời rạc hóa thành các mức phân loại nhằm phục vụ cho bài toán khai phá luật kết hợp. Các thuộc tính chính bao gồm: *temp_level, humidity_level, pressure_level, wind_level, cluster, extreme*

Ngoài ra, một biến nhãn mới *rain_label* được xây dựng từ lượng mưa (precipitation) nhằm biểu diễn trạng thái có mưa hay không. Cụ thể, nếu lượng mưa lớn hơn 0 thì gán nhãn *rain_yes*, ngược lại là *rain_no*.

```
df = df.withColumn(
    "rain_label",
    when(col("precipitation") > 0, "rain_yes")
    .otherwise("rain_no")
)
```

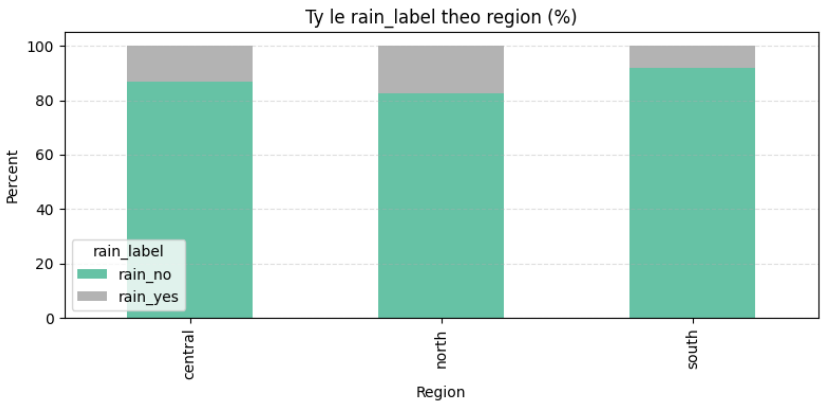

Figure 1: Biểu đồ phân bố tỉ lệ mưa/không mưa theo từng vùng

3.3.2 Biểu diễn dữ liệu dưới dạng transaction

Để áp dụng thuật toán khai phá luật kết hợp, mỗi bản ghi dữ liệu được chuyển thành một transaction dưới dạng danh sách các item. Mỗi item tương ứng với một thuộc tính rời rạc của dữ liệu.

Cụ thể, mỗi transaction được biểu diễn như sau:

$$[temp_level, humidity_level, wind_level, pressure_level, cluster, rain_label, extreme]$$

Quá trình xây dựng transaction được thực hiện bằng cách kết hợp các thuộc tính thành một mảng:

```
df = df.withColumn(
    "items_full",
    array(
        col("temp_level"),
        col("humidity_level"),
        col("wind_level"),
        col("pressure_level"),
        concat(lit("cluster_"), col("cluster")),
        col("rain_label"),
        col("extreme")
    )
)
```

Việc chuyển đổi này giúp dữ liệu phù hợp với yêu cầu đầu vào của thuật toán FPGrowth.

Table 3: Ví dụ biểu diễn dữ liệu dưới dạng transaction (items_full)

ID	items_full
1	[temp_high, humidity_low, wind_low, pressure_low, cluster_1, rain_no, heatwave]
2	[temp_medium, humidity_medium, wind_low, pressure_normal, cluster_1, rain_yes, normal]
3	[temp_low, humidity_high, wind_medium, pressure_high, cluster_2, rain_yes, heavy_rain]
4	[temp_high, humidity_low, wind_high, pressure_low, cluster_3, rain_no, heatwave]
5	[temp_medium, humidity_high, wind_low, pressure_normal, cluster_2, rain_yes, storm]

Dữ liệu được chia thành ba tập con tương ứng với ba vùng khí hậu:

- North
- Central
- South

Việc phân chia này giúp mô hình học được các quy luật đặc trưng riêng cho từng vùng, thay vì bị ảnh hưởng bởi sự khác biệt khí hậu giữa các khu vực.

```
df_north = df.filter(col("region") == "north")
df_central = df.filter(col("region") == "central")
df_south = df.filter(col("region") == "south")
```

3.3.3 Huấn luyện mô hình FPGrowth

Thuật toán FPGrowth được áp dụng riêng cho từng vùng với mục tiêu tìm các tập phổ biến và luật kết hợp.

Mô hình được cấu hình với các tham số:

- min_support = 0.005
- min_confidence = 0.1

Các giá trị này được lựa chọn nhằm đảm bảo có thể phát hiện được các pattern hiếm, đặc biệt là các hiện tượng thời tiết cực đoan.

Quá trình huấn luyện được thực hiện như sau:

```
fp = FPGrowth(
    itemsCol="items_full",
    minSupport=0.005,
    minConfidence=0.1
)

model = fp.fit(df_region)
```

Sau khi huấn luyện, mô hình sinh ra:

- Frequent itemsets
- Association rules

Table 4: Các frequent itemsets tiêu biểu theo từng vùng

Region	Itemset	Frequency
North	[wind_low]	1,537,216
North	[normal]	1,514,026
North	[pressure_normal]	1,237,151
Central	[wind_low]	1,052,823
Central	[normal]	1,035,363
Central	[pressure_normal]	978,837
South	[pressure_normal]	1,206,613
South	[normal]	1,202,376
South	[wind_low]	1,199,719

3.3.4 Trích xuất và lọc luật kết hợp

Từ tập các luật sinh ra, chỉ những luật liên quan đến các mục tiêu quan trọng mới được giữ lại, bao gồm:

- rain_yes
- heatwave
- heavy_rain
- storm

Quá trình lọc được thực hiện như sau:

```
rules = model.associationRules.filter(
    array_contains(col("consequent"), "rain_yes") |
    array_contains(col("consequent"), "heatwave") |
    array_contains(col("consequent"), "heavy_rain") |
    array_contains(col("consequent"), "storm")
)
```

Sau đó, các luật được sắp xếp theo độ đo *lift* giảm dần để ưu tiên các luật có mức độ liên hệ mạnh:

```
rules = rules.orderBy(col("lift").desc())
```

Table 5: Các luật kết hợp tiêu biểu theo độ đo lift ở ba vùng

Region	Antecedent	Consequent	Support	Confidence	Lift
North	[humidity_low, pressure_low, temp_high]	[heatwave]	0.0127	0.5036	27.57
North	[humidity_low, pressure_low]	[heatwave]	0.0127	0.5010	27.43
North	[humidity_low, pressure_low, wind_low]	[heatwave]	0.0127	0.5009	27.42
Central	[pressure_low, humidity_low, temp_high]	[heatwave]	0.0060	0.4506	17.89
Central	[pressure_low, humidity_low]	[heatwave]	0.0063	0.4293	17.05
Central	[pressure_low, humidity_low, rain_no]	[heatwave]	0.0060	0.4402	17.48
South	[cluster_1, temp_medium]	[rain_yes]	0.0099	0.1223	1.49
South	[cluster_1, temp_medium, wind_low]	[rain_yes]	0.0099	0.1223	1.49
South	[cluster_1, humidity_medium, temp_medium]	[rain_yes]	0.0087	0.1209	1.47

3.3.5 Trực quan hóa và phân tích

Các luật kết hợp được trực quan hóa nhằm hỗ trợ phân tích và rút ra insight. Các phương pháp trực quan hóa bao gồm:

- Biểu đồ scatter thể hiện mối quan hệ giữa support, confidence và lift
- Biểu đồ top các luật theo lift
- Heatmap thể hiện mức độ xuất hiện của các antecedent theo vùng
- Network graph mô tả mối quan hệ giữa các yếu tố thời tiết và các hiện tượng

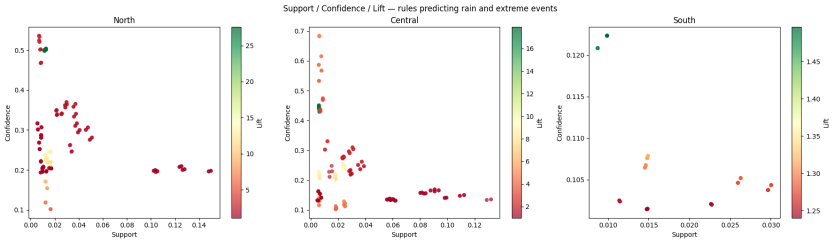

Figure 2: Biểu đồ thể hiện mối quan hệ giữa support, confidence và lift

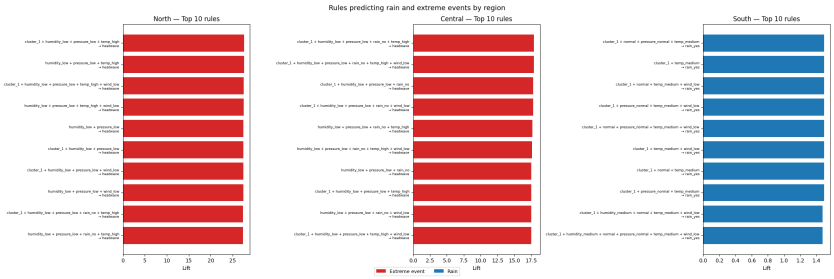

Figure 3: Những luật đặc biệt theo lift

Từ các kết quả thu được, có thể rút ra một số nhận xét chính:

- Độ ẩm cao kết hợp với áp suất thấp thường dẫn đến mưa
- Gió mạnh có xu hướng liên quan đến các hiện tượng bão
- Nhiệt độ cao và độ ẩm thấp có thể liên quan đến hiện tượng hạn hán
- Ở khu vực miền Nam thời tiết có xu hướng ôn hòa, ít xảy ra hiện tượng cực đoan hơn

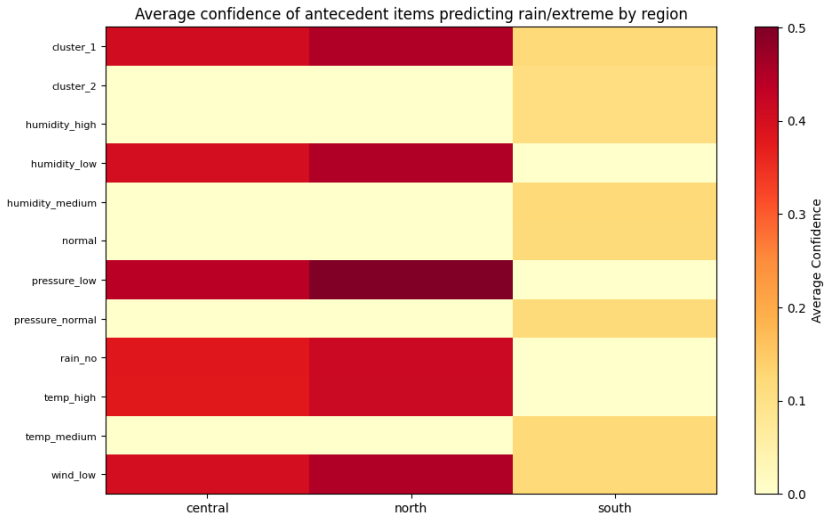

Figure 4: Heatmap thể hiện mức độ xuất hiện của các antecedent theo vùng

4 Xây dựng mô hình gom cụm (Clustering Algorithsm)

4.1 Mục tiêu

Mục tiêu của bài toán gom cụm là phân nhóm các tỉnh/thành phố tại Việt Nam dựa trên các đặc trưng khí tượng trung bình nhằm tìm ra các vùng có hình thái thời tiết tương đồng. Kết quả này giúp nhận diện cấu trúc khí hậu theo vùng, hỗ trợ trực quan hóa dữ liệu và cung cấp cơ sở cho các bài toán dự báo hoặc quy hoạch liên quan đến khí tượng.

4.2 Cơ sở lý thuyết

4.2.1 Nguyên lý hoạt động

Thuật toán K-Means được sử dụng để phân cụm dữ liệu. Đây là một thuật toán học không giám sát (*unsupervised learning*) phổ biến, có nhiệm vụ phân chia tập dữ liệu thành K cụm sao cho các điểm trong cùng một cụm có mức độ tương đồng cao nhất, hay tương đương với việc khoảng cách nội cụm là nhỏ nhất.

Hàm mục tiêu mà K-Means cần tối ưu hóa được biểu diễn như sau:

$$J = \sum_{j=1}^{K} \sum_{x_i \in C_j} \|x_i - \mu_j\|^2$$

Trong đó:

- K là số cụm cần phân chia
- C_j là tập các điểm dữ liệu thuộc cụm thứ j
- μ_j là tâm cụm (centroid) của cụm thứ j
- $\|x_i - \mu_j\|^2$ là bình phương khoảng cách Euclidean từ điểm x_i đến tâm cụm tương ứng

Thuật toán sẽ cố gắng tìm các tâm cụm sao cho tổng sai số bình phương trong nội bộ các cụm là nhỏ nhất.

4.2.2 Quy trình thực thi

Quy trình triển khai thuật toán bao gồm các bước lặp (*iterative*) sau:

1. Xác định số cụm K hợp lý mà dữ liệu cần phân chia.
2. Chọn ngẫu nhiên K điểm làm tâm của K cụm ban đầu. Trong mã nguồn, tham số `n_init = 10` được sử dụng để chạy thuật toán 10 lần với các điểm khởi tạo khác nhau, giúp giảm nguy cơ rơi vào cực trị địa phương.
3. Tính khoảng cách Euclidean từ mỗi thành phố đến tất cả các tâm cụm và gán điểm dữ liệu đó vào cụm có tâm gần nhất.
4. Cập nhật lại vị trí các tâm cụm bằng cách lấy trung bình cộng tọa độ của toàn bộ điểm dữ liệu thuộc từng cụm.
5. Lặp lại các bước gán cụm và cập nhật tâm cho đến khi vị trí các tâm cụm không còn thay đổi đáng kể hoặc đạt đến số lần lặp tối đa.

4.3 Các kỹ thuật bổ trợ trong bài toán

4.3.1 Chuẩn hoá dữ liệu

Việc sử dụng *StandardScaler* để chuẩn hoá dữ liệu là bước bắt buộc do các đặc trưng thời tiết có đơn vị đo và biên độ rất khác nhau. Chẳng hạn, áp suất khí quyển thường dao động quanh mức 1010 hPa, trong khi tốc độ gió chỉ vào khoảng 2–5 m/s. Nếu không chuẩn hoá, các biến có giá trị lớn sẽ chi phối hoàn toàn khoảng cách Euclidean, từ đó làm sai lệch quá trình gom cụm.

4.3.2 Phương pháp xác định K tối ưu

Nhóm sử dụng kết hợp hai kỹ thuật để đảm bảo việc lựa chọn số cụm mang tính khách quan hơn:

- **Elbow Method (phương pháp khuỷu tay):** Quan sát đồ thị *Inertia* theo K. Khi K tăng, *Inertia* luôn giảm; tuy nhiên, tại một số điểm tốc độ giảm sẽ chậm lại rõ rệt. Điểm "khuỷu tay" này chính là ứng viên phù hợp cho số cụm tối ưu.
- **Silhouette Analysis:** Chỉ số Silhouette $s(i)$ đo lường mức độ phù hợp của một điểm dữ liệu với cụm hiện tại so với các cụm lân cận.
  - $s(i) \approx 1$: điểm dữ liệu nằm rất xa các cụm khác, kết quả gom cụm tốt.
  - $s(i) \approx 0$: điểm dữ liệu nằm gần biên giữa hai cụm.
  - $s(i) < 0$: điểm dữ liệu có khả năng đã bị gán sai cụm.

Trong phần cài đặt, hàm `find_optimal_k` tự động lựa chọn giá trị K có điểm Silhouette trung bình cao nhất để đề xuất phương án phân cụm tối ưu.

4.3.3 Giảm chiều dữ liệu với PCA

Do dữ liệu thời tiết gồm nhiều đặc trưng như nhiệt độ, độ ẩm, áp suất, tốc độ gió và mức độ mây, việc quan sát trực tiếp trong không gian đa chiều là không khả thi. Vì vậy, thuật toán *Principal Component Analysis* (PCA) được áp dụng để chiếu dữ liệu xuống không gian hai chiều gồm PC1 và PC2, đồng thời vẫn giữ lại phần lớn phương sai của dữ liệu gốc. Kỹ thuật này giúp trực quan hoá sự phân tách giữa các cụm tỉnh/thành phố một cách rõ ràng hơn.

4.4 Phân tích kết quả và nhận xét

4.4.1 Xác định số cụm tối ưu

Dựa trên kết quả từ hai phương pháp đánh giá phổ biến, nhóm lựa chọn $K = 4$ là số cụm phù hợp nhất:

- **Phương pháp khuỷu tay (Elbow Method):** Đồ thị cho thấy mức giảm của *Inertia* bắt đầu chậm lại đáng kể từ $K = 4$. Đây là điểm cân bằng giữa độ phức tạp của mô hình và khả năng giảm sai số nội cụm.
- **Chỉ số Silhouette:** Giá trị Silhouette trung bình đạt cao nhất tại $K = 4$ (xấp xỉ 0.447), cho thấy cấu trúc dữ liệu được phân tách rõ ràng nhất khi chia thành bốn nhóm.

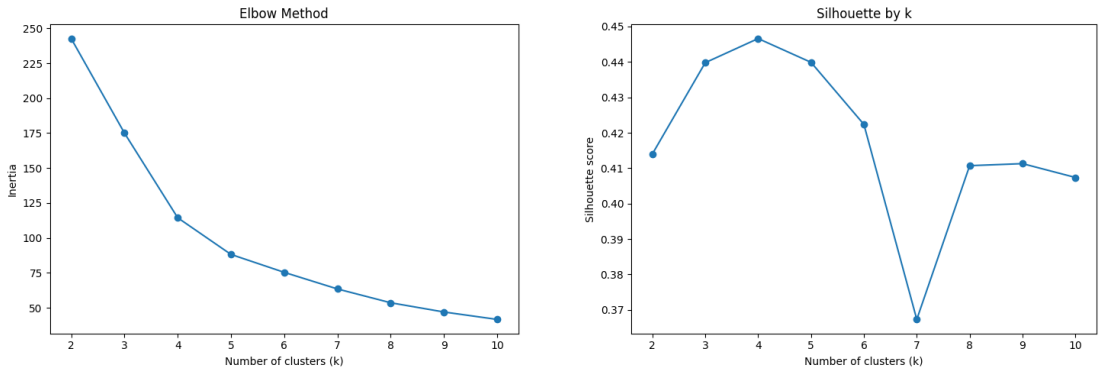

Figure 5: Đồ thị Elbow Method và Silhouette Analysis để lựa chọn số cụm tối ưu

4.4.2 Đặc điểm của các cụm

Phân tích giá trị trung bình tại tâm cụm (*centroids*) cho phép xác định hình thái thời tiết đặc trưng của từng nhóm như sau:

Đặc trưng	**Cụm 0**	**Cụm 1**	**Cụm 2**	**Cụm 3**
Nhiệt độ (°C)	24.86	27.86	28.01	28.58
Độ ẩm (%)	88.24	80.11	78.74	78.92
Tốc độ gió (m/s)	1.40	2.51	3.80	3.15
Mức độ mây (%)	82.48	81.80	85.55	36.69

Table 6: Giá trị trung bình các đặc trưng tại tâm cụm

Từ bảng trên có thể gán nhãn diễn giải cho các cụm như sau: cụm 0 là vùng cao hoặc nội địa, cụm 1 là đồng bằng Bắc Bộ và Bắc Trung Bộ, cụm 2 là duyên hải hoặc miền Nam, trong khi cụm 3 đại diện cho nhóm đô thị có độ che phủ mây thấp.

4.4.3 Nhận xét chi tiết

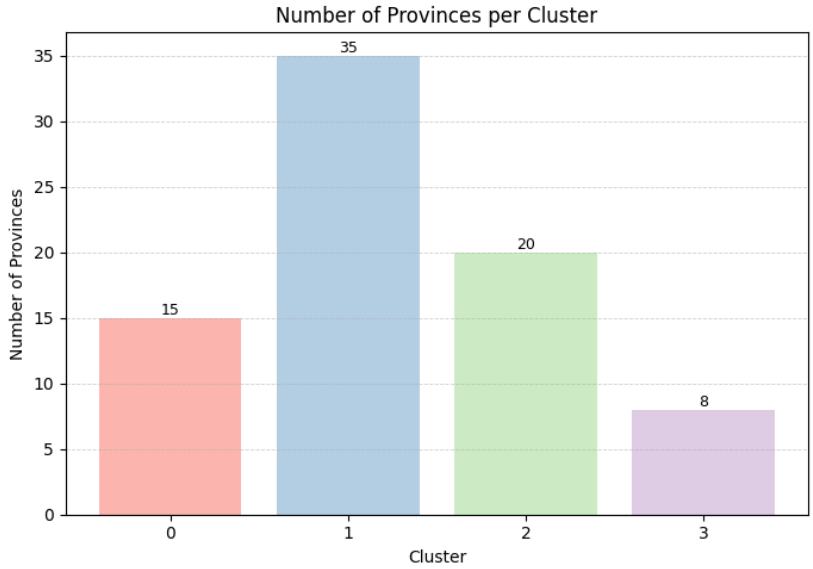

Figure 6: Phân bố số lượng tỉnh/thành phố theo từng cụm

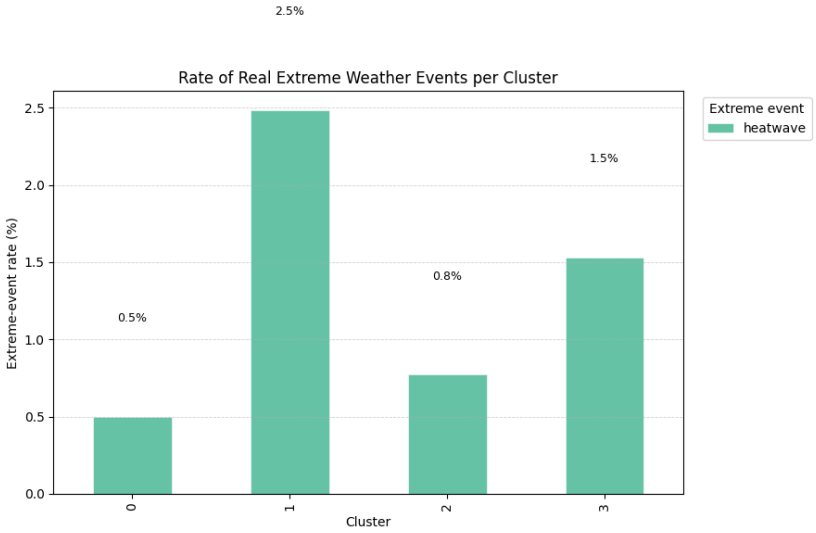

Figure 7: Mối liên hệ giữa các cụm và nguy cơ nắng nóng

1. **Sự phân hoá theo địa hình và vùng miền**

   - **Cụm 0 (15 thành phố):** Bao gồm nhiều tỉnh miền núi phía Bắc như Lào Cai, Hà Giang, Lạng Sơn và một số khu vực Tây Nguyên như Pleiku, Kon Tum, Gia Nghĩa. Đặc trưng nổi bật là nhiệt độ thấp nhất (khoảng 24.8°C), độ ẩm cao và tốc độ gió thấp do ảnh hưởng của địa hình đồi núi.
     Dự đoán: Do độ ẩm cực cao, đây không phải vùng trọng điểm của nắng nóng nhưng là khu vực cần chú trọng dự báo mưa phùn, mưa dầm và sương mù dày đặc gây ảnh hưởng đến tầm nhìn.

   - **Cụm 1 (35 thành phố):** Tập trung các tỉnh đồng bằng Bắc Bộ và Bắc Trung Bộ như Hà Nội, Hải Dương, Thanh Hóa và Vinh. Đây là nhóm chiếm đa số và mang đặc điểm thời tiết trung bình, tương đối điển hình, với độ phủ mây cao.
     Dự đoán: Kết hợp với luật kết hợp `[humidity_low, pressure_low] →heatwave`, Cụm 1 cần được ưu tiên trong các hệ thống cảnh báo sớm nắng nóng quy mô lớn.

   - **Cụm 2 (20 thành phố):** Chủ yếu gồm các thành phố thuộc khu vực duyên hải và Tây Nam Bộ như Vũng Tàu, Cà Mau, Rạch Giá, Tuy Hòa. Đặc trưng nổi bật là tốc độ gió cao nhất (3.8 m/s), phản ánh tác động của gió biển và địa hình bằng phẳng.
     Dự đoán: Thay vì nắng nóng, mục tiêu dự báo trọng điểm cho Cụm 2 phải là gió giật mạnh và các hiện tượng thời tiết cực đoan liên quan đến bão (*storm*).

2. **Nhóm đô thị đặc thù (Cụm 3)**

   - **Cụm 3 (8 thành phố):** Bao gồm các trung tâm kinh tế lớn như TP. Hồ Chí Minh, Đà Nẵng, Hải Phòng cùng các đô thị công nghiệp như Thuận An và Dĩ An. Nhóm này có độ phủ mây thấp nhất (chỉ khoảng 36.69%) và nhiệt độ trung bình cao nhất. Hiện tượng này có thể liên quan đến hiệu ứng "đảo nhiệt đô thị" (*Urban Heat Island*), khi mật độ xây dựng cao làm tăng khả năng hấp thụ và giữ nhiệt của bề mặt.
     Dự đoán: Do hiệu ứng "đảo nhiệt đô thị", các thành phố lớn như TP. HCM, Đà Nẵng, Hải Phòng có nguy cơ nắng nóng gay gắt cục bộ, ngay cả khi các vùng lân cận có nhiệt độ thấp hơn.

4.4.4 Phân tích không gian PCA

Biểu đồ PCA cho thấy sự tách biệt tương đối rõ giữa các cụm trong không gian hai chiều:

- Thành phần chính thứ nhất (PC1), chiếm khoảng 50.3% thông tin, chủ yếu phân tách các thành phố theo nhiệt độ và độ ẩm. Cụm 0 nằm lệch hẳn về một phía, thể hiện sự khác biệt rõ so với các cụm còn lại.

- Thành phần chính thứ hai (PC2) hỗ trợ phân biệt dựa trên tốc độ gió và độ phủ mây. Cụm 3 nằm tách biệt ở phía dưới đồ thị do có giá trị mây thấp bất thường so với các nhóm khác.

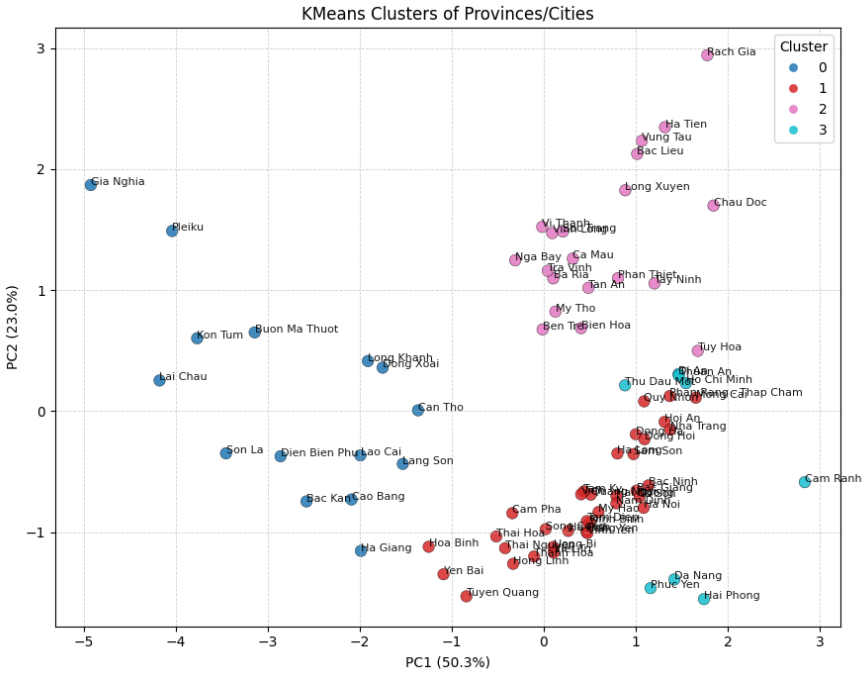

Figure 8: Biểu đồ PCA minh hoạ kết quả phân cụm K-Means

4.4.5 Kết luận

Kết quả gom cụm bằng thuật toán K-Means đã phản ánh khá rõ sự phân hoá khí hậu tại Việt Nam không chỉ theo trục Bắc – Nam mà còn theo đặc điểm địa hình như miền núi, đồng bằng và duyên hải. Đặc biệt, nhóm các đô thị lớn được tách thành một cụm riêng với các dấu hiệu đặc trưng về nhiệt độ và mức độ che phủ mây. Kết quả này cung cấp thông tin hữu ích cho các bài toán dự báo nhu cầu năng lượng, quy hoạch đô thị bền vững và phân tích đặc điểm khí hậu theo vùng.

5 Phân loại thời tiết cực đoan bằng học máy (Classification)

5.1 Mục tiêu của bài toán phân lớp

Mục đích cốt lõi của bài toán phân lớp trong nghiên cứu này không chỉ dừng lại ở việc dự đoán, mà hướng tới giải quyết các bài toán thực tiễn trong khí tượng học thông qua ứng dụng học máy. Cụ thể, bài toán đặt ra ba mục tiêu chính:

- **Xây dựng hệ thống cảnh báo sớm (Early Warning System):** Mục tiêu quan trọng nhất là phát triển một mô hình có khả năng tự động nhận diện và cảnh báo sớm các hiện tượng thời tiết cực đoan (như `heatwave`, `storm`) cũng như tình trạng mưa dựa trên các chỉ số khí tượng cơ bản. Việc dự báo sớm góp phần giảm thiểu rủi ro và thiệt hại cho các hoạt động kinh tế – xã hội.

- **Hỗ trợ ra quyết định thực tiễn:** Xây dựng một công cụ phân loại có độ tin cậy cao nhằm hỗ trợ người dùng cuối trong các lĩnh vực ứng dụng. Ví dụ, dự đoán mưa giúp tối ưu hóa lịch trình trong nông nghiệp hoặc giao thông vận tải, trong khi cảnh báo nắng nóng hỗ trợ ngành y tế và điện lực trong việc chuẩn bị các phương án ứng phó.
- **Đánh giá và tối ưu hóa hiệu năng thuật toán:** Thực hiện so sánh trực tiếp hai mô hình học tổ hợp tiên tiến (*Ensemble Learning*) là Random Forest và XGBoost trên bộ dữ liệu thực tế có đặc thù mất cân bằng lớp (*class imbalance*) nghiêm trọng. Qua đó, xác định mô hình tối ưu có khả năng cân bằng giữa việc hạn chế bỏ sót các hiện tượng hiếm gặp (Recall cao) và giảm thiểu cảnh báo giả (Precision cao).

5.2 Giới thiệu và khắc phục mất cân bằng dữ liệu

Bài toán đặt ra yêu cầu phân loại tình trạng thời tiết dựa trên các dữ liệu khí tượng thông qua hai mục tiêu độc lập: dự đoán khả năng có mưa (`Rain`/`No Rain`) và cảnh báo thời tiết cực đoan (`Normal`, `Heatwave`, `Storm`, ...).

Để đảm bảo tính khách quan, các thuộc tính gây rò rỉ dữ liệu (*data leakage*) như `weather_description` hay `rainfall` đã được loại bỏ khỏi tập huấn luyện.

Thách thức lớn nhất trong bộ dữ liệu là sự mất cân bằng lớp (*class imbalance*) nghiêm trọng. Để khắc phục, kỹ thuật SMOTE với tham số $k = 3$ láng giềng gần nhất được áp dụng trên tập huấn luyện (80% dữ liệu).

Hai thuật toán học tổ hợp được lựa chọn để so sánh là:

- Random Forest (`class_weight = "balanced"`)
- XGBoost

5.3 Đánh giá tổng quan qua các chỉ số (Metrics)

[BẢNG SO SÁNH EXTREME TRÊN TẬP TEST]

Model	AUC (OVR)	Accuracy	Recall	Precision
Random Forest - Extreme	0.9998	0.9962	0.9933	0.9048
XGBoost - Extreme	0.9999	0.997	0.9943	0.9223

[BẢNG SO SÁNH RAIN TRÊN TẬP TEST]

Model	AUC	Accuracy	Recall	Precision
Random Forest - Rain	0.8784	0.8016	0.7916	0.6707
XGBoost - Rain	0.8402	0.8838	0.5884	0.8364

Figure 9: Bảng kết quả đánh giá trên tập kiểm thử

Kết quả đánh giá trên tập kiểm thử độc lập (20% dữ liệu) cho thấy sự khác biệt rõ rệt trong đặc tính học của hai thuật toán:

Đối với bài toán Extreme

Cả hai mô hình đều đạt hiệu năng rất cao với Accuracy và AUC tiệm cận 1. Tuy nhiên, XGBoost nhỉnh hơn ở hầu hết các chỉ số, đặc biệt là Precision đạt 0.9223 so với 0.9048 của Random Forest.

Đối với bài toán Rain

Xuất hiện sự đánh đổi (*trade-off*) rõ rệt giữa Precision và Recall. Random Forest vượt trội về Recall (0.7916 so với 0.5884 của XGBoost) nhưng lại thấp hơn về Precision (0.6707 so với 0.8364). Để hiểu rõ hơn hiện tượng này, cần phân tích chi tiết qua ma trận nhầm lẫn.

5.4 Phân tích chi tiết: Dự đoán mưa (Rain)

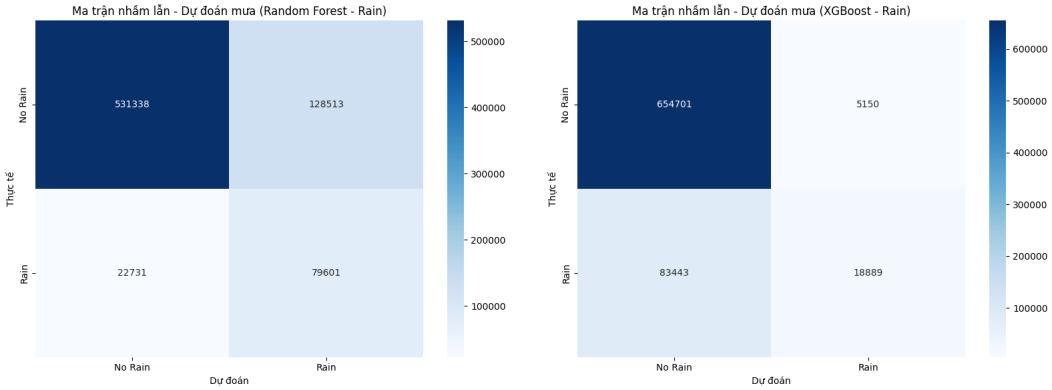

Figure 10: Ma trận nhầm lẫn cho bài toán dự đoán mưa (Random Forest và XGBoost)

Hai ma trận nhầm lẫn cho thấy chiến lược dự đoán hoàn toàn khác nhau của hai mô hình:

Random Forest (nhạy cảm nhưng dễ báo động giả)

Mô hình này thiên về việc "bắt nhầm còn hơn bỏ sót". Nó dự đoán đúng 79,601 trường hợp có mưa (giải thích cho Recall cao). Tuy nhiên, số lượng báo động giả (*False Positives*) rất lớn, lên tới 128,513 trường hợp thực tế không mưa nhưng bị dự đoán có mưa.

XGBoost (thận trọng và chính xác)

Mô hình này thận trọng hơn khi dự đoán có mưa. Số lượng báo động giả được giảm xuống mức rất thấp (5,150 trường hợp). Tuy nhiên, hệ thống bỏ sót 83,443 trường hợp thực tế có mưa (*False Negatives*), chỉ nhận diện đúng 18,889 trường hợp.

Tùy thuộc vào yêu cầu nghiệp vụ, có thể lựa chọn mô hình phù hợp: XGBoost nếu cần độ chính xác cao, hoặc Random Forest nếu ưu tiên khả năng bao phủ cảnh báo.

5.5 Phân tích chi tiết: Cảnh báo thời tiết cực đoan (Extreme)

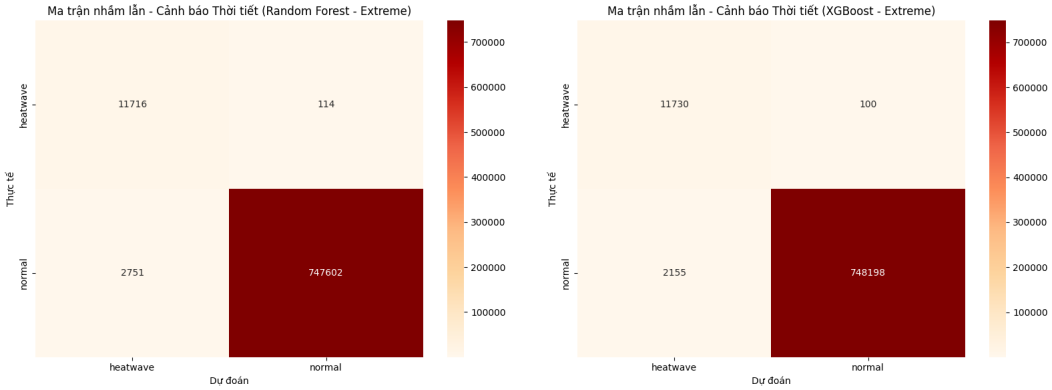

Figure 11: Ma trận nhầm lẫn cho bài toán thời tiết cực đoan (Random Forest và XGBoost)

Đối với bài toán nhận diện thời tiết cực đoan, cả hai mô hình đều thể hiện hiệu năng ổn định và chính xác cao.

Khả năng nhận diện lớp thiểu số `heatwave` của hai mô hình gần như tương đương (11,716 trường hợp đúng của Random Forest so với 11,730 của XGBoost).

Tuy nhiên, XGBoost tối ưu tốt hơn trong việc giảm thiểu nhầm lẫn. Số trường hợp `normal` bị dự đoán sai thành `heatwave` chỉ là 2,155, thấp hơn so với 2,751 của Random Forest.

Kết luận

XGBoost là lựa chọn ưu việt hơn cho bài toán cảnh báo thời tiết cực đoan. Trong khi đó, bài toán dự báo mưa cần được tinh chỉnh thêm ngưỡng phân loại (*decision threshold*) tùy theo yêu cầu triển khai thực tế.

6 Giao diện trực quan hệ thống

Để hỗ trợ việc khai thác và phân tích dữ liệu một cách trực quan, hệ thống được xây dựng với giao diện người dùng bao gồm nhiều chức năng chính.Ở đề tài này, Streamlit là nền tảng được lựa chọn để biểu diễn giao diện hệ thống

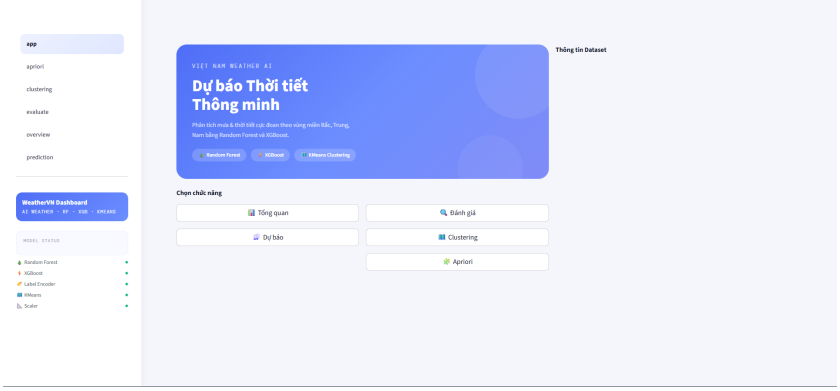

Figure 12: Giao diện chính của hệ thống

Giao diện tổng quan cung cấp cái nhìn chung về dữ liệu thời tiết, cho phép người dùng quan sát nhanh các đặc trưng chính của tập dữ liệu.

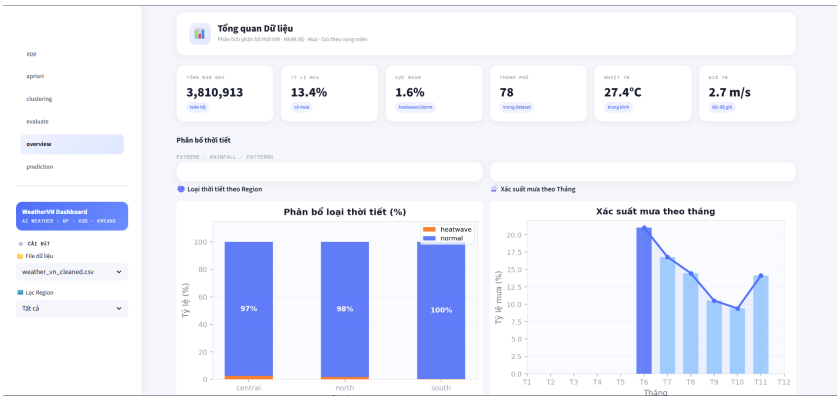

Figure 13: Tổng quan dữ liệu

Tiếp theo, giao diện khai phá luật kết hợp (Apriori/FPGrowth) cho phép hiển thị các luật kết hợp được sinh ra, kèm theo các độ đo như *support*, *confidence* và *lift*. Người dùng có thể dễ dàng theo dõi và đánh giá các luật quan trọng.

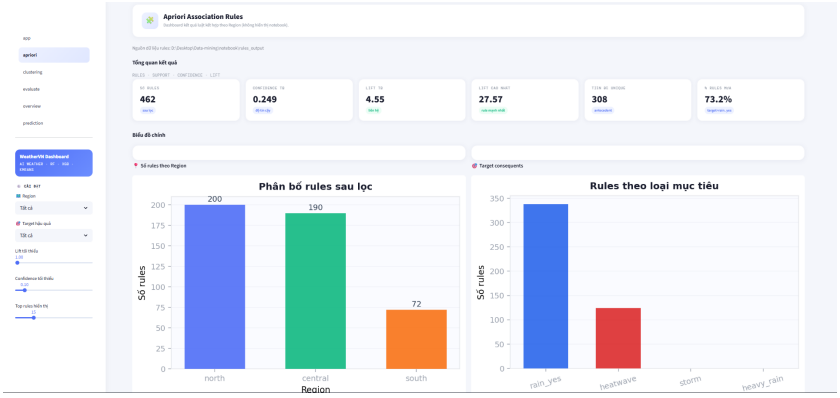

Figure 14: Giao diện khai phá luật kết hợp

Giao diện phân cụm (Clustering) giúp trực quan hóa kết quả phân nhóm dữ liệu, từ đó hỗ trợ việc nhận diện các nhóm thời tiết có đặc điểm tương đồng.

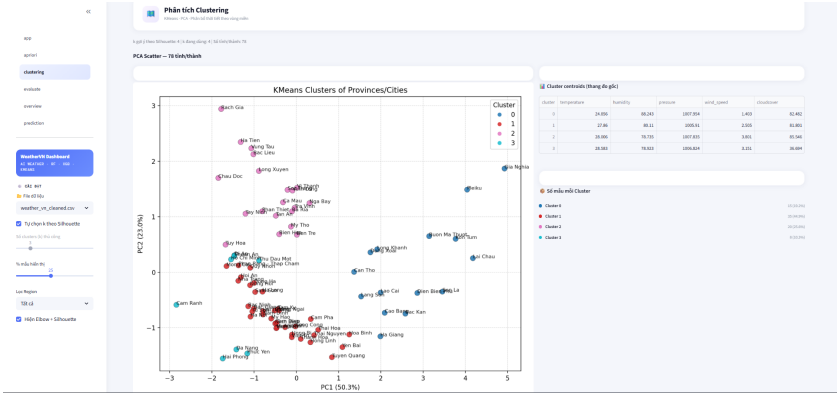

Figure 15: Phân cụm dữ liệu theo tỉnh thành

Ngoài ra, giao diện dự đoán (Prediction) cho phép người dùng nhập các thông số thời tiết và nhận kết quả dự đoán tương ứng, hỗ trợ việc ứng dụng mô hình vào thực tế.

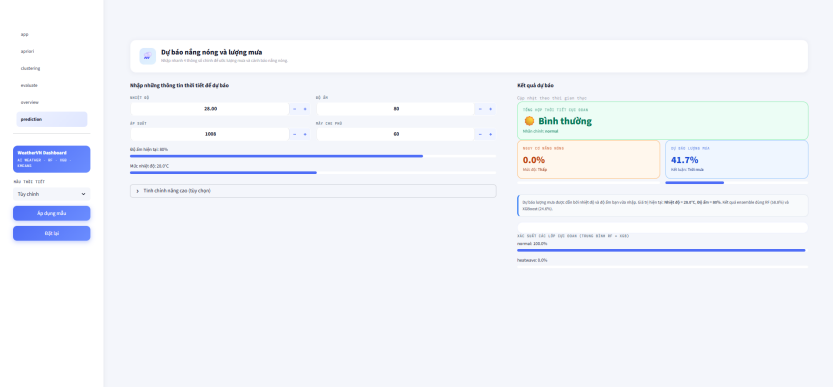

Figure 16: Dự đoán mưa và thời tiết cực đoan

7 Kết luận và ra quyết định

Đề tài đã xây dựng một hệ thống phân tích dữ liệu thời tiết hoàn chỉnh, bao gồm các bước từ tiền xử lý dữ liệu, khai phá luật kết hợp, gom cụm đến xây dựng mô hình dự báo mưa và thời tiết cực đoan. Thông qua việc kết hợp các kỹ thuật khai phá dữ liệu và học máy, hệ thống không chỉ giúp hiểu rõ hơn về đặc điểm thời tiết mà còn có khả năng hỗ trợ đưa ra các quyết định cụ thể trong thực tế.

Cụ thể, các kết quả từ mô hình có thể được ứng dụng trực tiếp trong nhiều kịch bản ra quyết định. Ví dụ, dự đoán mưa có thể hỗ trợ người dùng quyết định có nên tổ chức hoạt động ngoài trời, điều chỉnh lịch trình di chuyển hoặc chuẩn bị phương án che chắn. Trong lĩnh vực nông nghiệp, thông tin về khả năng mưa hoặc nắng nóng giúp người nông dân quyết định thời điểm tưới tiêu, gieo trồng hoặc thu hoạch. Đối với các hiện tượng thời tiết cực đoan như bão hoặc nắng nóng, hệ thống có thể hỗ trợ các cơ quan hoặc cá nhân đưa ra quyết định phòng tránh sớm, giảm thiểu rủi ro và thiệt hại.

Ngoài ra, kết quả gom cụm giúp phân loại các khu vực có đặc điểm khí hậu tương đồng, từ đó hỗ trợ việc đưa ra các quyết định mang tính khu vực, chẳng hạn như quy hoạch đô thị, phân bổ tài nguyên hoặc xây dựng chính sách phù hợp với từng vùng. Các luật kết hợp cũng cung cấp những dấu hiệu nhận biết sớm, giúp người dùng đưa ra quyết định nhanh chóng mà không cần phân tích dữ liệu phức tạp.

Tuy nhiên, hệ thống vẫn tồn tại một số hạn chế. Dữ liệu hiện tại chủ yếu mang tính ngắn hạn nên chưa hỗ trợ tốt cho các quyết định dài hạn. Độ chính xác của mô hình trong một số trường hợp hiếm vẫn còn hạn chế, có thể ảnh hưởng đến độ tin cậy khi ra quyết định. Ngoài ra, hệ thống hiện mới dừng lại ở việc cung cấp dự đoán mà chưa đưa ra các khuyến nghị hành động cụ thể một cách tự động.

Trong tương lai, hệ thống có thể được phát triển theo hướng trở thành một công cụ hỗ trợ ra quyết định hoàn chỉnh hơn. Cụ thể, có thể tích hợp cơ chế gợi ý hành động (recommendation), ví dụ như tự động đề xuất hoãn lịch, cảnh báo nguy hiểm hoặc đưa ra phương án ứng phó phù hợp với từng tình huống thời tiết. Bên cạnh đó, việc mở rộng dữ liệu theo thời gian và tích hợp thêm các nguồn dữ liệu khác sẽ giúp nâng cao độ chính xác, từ đó cải thiện chất lượng các quyết định được đưa ra.

Tổng thể, đề tài không chỉ dừng lại ở việc phân tích dữ liệu mà đã bước đầu hướng đến việc hỗ trợ ra quyết định trong thực tế, mở ra tiềm năng phát triển thành các hệ thống ứng dụng thông minh phục vụ đời sống.

8 Link github và slide của dự án

Toàn bộ dự án được thực hiện và triển khai trên github. Link dẫn đến repo dự án: https://github.com/itzKieuMinh05/CO3029-Weather_forecasting
Link slide của dự án: https://canva.link/wsntu1hnamxvcxq